

Adaptive-RAG 技術重點整理與架構分析

概述 (Overview)

Adaptive-RAG (Adaptive Retrieval-Augmented Generation, 自適應檢索增強生成) 是一種依據 **查詢複雜度 (Question Complexity)** 動態調整檢索策略的 LLM 增強框架。此論文發表於 arXiv (arXiv:2403.14403)。

傳統的 RAG 系統大多採取「單一模式 fits all」的設計——對所有問題均執行固定次數的向量檢索，或者完全不檢索。Adaptive-RAG 的目標是在 **計算效率 (Computational Efficiency)** 與 **回答準確度 (Response Accuracy)** 之間取得最佳平衡。

核心架構與元件 (Core Architecture & Components)

Adaptive-RAG 的架構主要由以下三大模組構成：

1. 複雜度分類器 / 路由 (Complexity Classifier / Router)

- 使用輕量級的語言模型作為 Classifier。
- 當使用者輸入 Query 時，分類器首先評估該查詢的複雜程度。
- 將問題分類為不同的複雜度層級（如簡單事實、中等複雜度、多跳/跨文檔複雜問題）。

2. 多階層檢索策略 (Multi-Tiered Retrieval Strategies)

依據分類器的判定結果，系統自動切換至相應的處理解法：

* **無須檢索 (No-Retrieval)**：若問題屬於 LLM 內部參數知識即可解答的簡單常識或基礎問答，直接由 LLM 生成回答，省去外部檢索開銷。

* **單步檢索 (Single-Step Retrieval)**：若問題需要單一外部事實佐證，執行標準的單次向量檢索並結合 Context 生成回答。

* **多步/疊代檢索 (Multi-Step / Iterative Retrieval)**：針對複雜、多跳 (Multi-hop) 或需綜合推理的問題，啟動多輪疊代檢索與推論鏈，逐步收集所需上下文。

3. 自動化標籤訓練機制 (Automatic Labeling)

- 為了解決缺乏「查詢與最佳 RAG 策略對應」標註資料的問題，作者設計了自動生成訓練集的標註機制。
- 將訓練問題通過各種策略測試，紀錄能正確回答問題且資源消耗最少的策略作為 Ground Truth 標籤，用以訓練分類器。

策略對比與優劣勢 (Pros & Cons)

評估維度	Naive RAG (傳統 RAG)	Adaptive-RAG (自適應 RAG)
檢索開銷	固定高開銷（對簡單問題亦執行檢索）	最佳化（簡單問題不檢索，省時省算力）
複雜問題解答能力	有限（單次檢索無法涵蓋多跳推論）	極佳（自動切換為多步疊代檢索）
延遲 (Latency)	平均延遲固定	簡單問題反應迅速，複雜問題精確深入

適用場景 (Use Cases)

- 企業級智慧客服與知識庫：**處理大量多樣化的用戶提問，能同時兼顧即時常見問答與複雜產品故障排查。
- 多跳問答系統 (Multi-hop Question Answering)：**如法規檢索、醫療診斷支援等需要綜合多個文件段落的領域。
- 成本敏銳型 AI 應用：**顯著降低向量數據庫 (Vector DB) 與 API 檢索的請求次數與費用。